

웹크롤러 구상안

작성자 김준영

목적

경쟁사 정수기 제품의 외부 시장 반응 데이터를 주기적으로 수집하고, 이를 실적 분석 및 예상 Report 생성 시 활용 가능한 근거 데이터로 정리하는 것을 목적으로 한다.

수집 대상은 경쟁사 제품의 판매 조건, 가격, 렌탈료, 프로모션, 뉴스, 블로그/카페 반응, 댓글, 리뷰, 검색 관심도 등이다.

수집된 웹 데이터는 판매량 예측 모델 결과 및 상관변수 분석 모델 결과와 함께 LLM에 입력되어, 전월/전년도 대비 실적 변화 원인과 향후 예상에 대한 설명형 보고서 생성에 활용된다.

범위

- 웹 데이터 수집
- 원문/정제 데이터 저장
- 제품/브랜드 매칭
- 시장 이벤트 요약




그림 1. 웹 크롤링 데이터와 분석 모델 결과를 결합한 LLM 리포트 생성 흐름

구성

1. 스케줄러

정해진 주기에 따라 크롤링 작업 실행

표 1. 스케줄러 주기

종류	주기	대상	목적
기본 정기 크롤링	일 1회	공식물, 쇼핑몰, 뉴스, 블로그/카페, 댓글 등 전체 수집 대상	전일 기준 시장 반응 데이터를 누락 없이 축적
가격/프로모션	일 1회	공식물, 쇼핑몰, 가격비교 페이지 등	가격, 렌탈료, 할인, 프로모션 문구 변화 추적
뉴스/블로그	일 1회	뉴스, 블로그, 카페글, 검색 API	신제품 출시, 광고/캠페인, 부정 이슈, 소비자 반응 변화 수집

2. 웹 크롤러

공식물, 쇼핑몰, 뉴스 등 외부 데이터 수집

3. Raw file 저장소

수집한 원본 HTML, Text, Json 원본 저장

4. DuckDB 저장소

Raw 메타데이터, 정제 데이터, 시장 이벤트 데이터 저장

5. 전처리 및 이벤트 추출

중복 제거, 본문 추출, 제품/브랜드 매칭, 가격/프로모션 정규화 등

6. LLM 리포트 입력 데이터 생성

웹 크롤링 결과, 상관분석 모델 결과, 판매량 예측 모델 결과를 결합해 LLM에 넣을 입력 데이터 생성

동작 시나리오

1. 정기적 크롤링

스케줄러는 매일 정해진 시간에 크롤링 작업을 실행한다. 웹 크롤러는 경쟁사 공식물, 쇼핑몰, 뉴스 등에서 정수기 제품 관련 데이터를 수집한다. 수집된 원본 HTML, Text, JSON 데이터는 Raw file 저장소에 저장하고, URL, 수집 시각, 출처, 파일 경로 등의 메타데이터는 DuckDB에 저장한다.

2. 전처리 및 이벤트 추출

수집된 Raw 데이터에 대해 중복 제거, 본문 추출, 제품/브랜드 매칭, 가격/프로모션 정보 정

규화 작업을 수행한다. 이후 신제품 출시, 가격 변동, 프로모션, 광고/캠페인, 긍정/부정 이슈, 소비자 반응 변화 등의 시장 이벤트를 추출한다. 전처리 결과와 이벤트 데이터는 DuckDB에 저장하여 기간별, 제품별, 출처별로 조회할 수 있도록 구성한다.

3. Report 생성

사용자가 특정 기간의 실적 분석 및 예상 Report 생성을 요청하면, 시스템은 해당 기간의 웹 크롤링 데이터를 DuckDB에서 조회한다. 이후 판매량 예측 모델 결과와 상관변수 분석 모델 결과를 함께 결합하여 LLM 입력 데이터를 생성한다. LLM은 모델 결과와 웹 시장 반응 근거를 종합하여 전월/전년도 대비 실적 변화 원인과 향후 예상에 대한 설명형 Report를 생성한다.

기술/모델 스택

1. 개발 언어

- Python

2. 크롤링

- requests: 정적 페이지 및 API 호출 기반 데이터 수집
- BeautifulSoup 또는 selectolax: HTML 파싱
- Playwright: JavaScript 렌더링이 필요한 페이지 수집
- 네이버 검색/데이터랩 API: 뉴스, 블로그, 카페글, 검색 관심도 데이터 수집

3. 데이터 저장

- Raw file storage: 원본 HTML, Text, JSON 파일 저장
- DuckDB: Raw 메타데이터, 정제 데이터, 시장 이벤트 데이터 저장
- Parquet: 필요 시 대용량 정제 데이터 저장 및 백업

4. 데이터 전처리

- polars: 수집 데이터 정제 및 테이블 처리
- regex: 제품명, 가격, 렌탈료, 프로모션 문구 추출
- hashlib: URL/본문 기반 중복 제거
- trafilatura: 뉴스/블로그 본문 추출

5. AI/LLM 활용

- 제품/브랜드 매칭 보조
- 문서 이벤트 유형 분류
- 뉴스/댓글/리뷰 요약

- 긍정/부정/중립 반응 분류
- LLM Report 입력 데이터 요약 및 구조화

6. 스케줄링/운영

- APScheduler 작업 스케줄러
- logging: 크롤링 성공/실패 로그 기록

검토 필요 사항

1. 웹 크롤러 차단 대응

- 수집 대상 사이트의 robots.txt 및 이용약관 확인 필요
- CAPTCHA 쓰는 곳은 수집 대상에서 제외

2. 데이터 정규화

- 정규화 작업, 정규식만으로는 불가함 regex로 1차 정제하고, 비교적 가벼운 모델 api로 구조화 검토 필요

3. 비용 최적화

- LLM Report 입력 데이터 요약 및 구조화 상세 검토 필요

4. 스케줄러 가능성 검토

- 정기적으로 크롤링 하려면 계속 켜놔야하므로, 24시간 운영 가능한지 검토 필요

5. 데이터 보존 정책

- Raw 파일은 용량 증가를 고려해 일정 기간 보관 후 삭제
- 정제 데이터와 시장 이벤트 데이터는 전월/전년도 비교를 위해 장기 보관