

정수기 구독 계정 신규·해지 예측 모델 구상안

작성자 홍화수

목적

정수기 구독 계정의 신규·해지 데이터를 기반으로 향후 수개월의 신규·해지 계정수(건수)를 정량적으로 예측하는 것을 목적으로 한다. 예측 결과는 순증·활성계정 추이 추정과 향후 실적 전망의 근거로 활용되며, 상관변수 분석 모델·웹 크롤링 결과와 함께 LLM 설명형 보고서의 입력 데이터로 제공된다. 매출(구독료) 환산은 모델별 단가표가 주어질 경우의 확장 기능으로 두며, 본 모델의 직접 예측 대상은 '계정수(건수)'이다.

범위

- ▶ 월별 신규·해지·재구독률 시계열 예측 (전체 합계 기준)
- ▶ 백테스트 기반 예측 모델 선정 및 정확도(MAPE) 평가
- ▶ 만기 계정수 확정 계산 (계약 코호트 carry-forward)
- ▶ 활성계정·해지율·매출 항등식 결합 (외부 base·단가표 입력 시)
- ▶ 기존 Streamlit 대시보드 연동 및 보고서 입력 데이터 생성




그림 1. 시계열 데이터 → 모델 선정·예측 → 대시보드 / 보고서 입력 흐름

추진 방식 — 두 단계로 운영한다. ① 모델 선정(분기 1회): 백테스트로 후보를 비교해 타깃별 최선 모델 1개를 고정한다. ② 예측(평소·매월): 고정된 모델 하나만으로 신규·해지를 예측한다. 평소에는 모델 1개만 동작하여 가볍고 단순하다.

구성

1. 데이터 로더

SummaryDB(Parquet)에서 월별 계정수 시계열 집계(duckdb). 불완전·결측치 제거, 분석구간 정규화.

2. 모델 후보

Seasonal-Naive(전년동월 베이스라인), ARIMA / SARIMA, ETS(지수평활). 채널별 세분화 보조로 Gradient Boosting.

3. 모델 선정기 (백테스트)

Rolling-origin 1-step 백테스트로 후보별 평균오차(MAPE) 산출 → 최저 모델 1개를 타깃별로 선정·고정.

4. 예측기

선정·고정된 모델을 최신 시계열에 적합해 향후 N개월 예측값과 신뢰구간을 산출.

5. 확정 계산 · 항등식

만기는 코호트 carry-forward로 확정 계산. 활성계정·해지율·매출은 항등식(활성=전월활성+신규해지만기)으로 결합.

6. 저장 · 조회

예측 결과를 Parquet으로 저장하고 DuckDB로 조회. 입력 변경 전까지 재학습을 막는 캐시 적용.

7. 대시보드 연동

render_dashboard 플러그인으로 기존 운영 시스템에 '예측' 탭을 추가(앱 본문 변경 최소).

예측 대상	예측 방식	검증 정확도(1개월 앞)	신뢰 지평선
신규 건수	시계열 예측(고정 모델)	MAPE 약 10.8%	3개월
해지 건수	시계열 예측(고정 모델)	MAPE 약 8.7%	3개월
재구독률	시계열 예측(고정 모델)	MAPE 약 13%	3개월
만기 건수	코호트 확정 계산	해당 없음(확정)	—
활성·해지율·매출	항등식 + 외부 입력	외부 base·단가 필요	—

표 1. 예측 대상 및 방식 (정확도는 실데이터 rolling-origin 백테스트 기준)

동작 시나리오

1. 모델 선정 (분기 1회 또는 데이터 갱신 시)

과거 월별 시계열에 대해 후보 모델들을 Rolling-origin 백테스트한다. 각 후보가 과거 약 12개 시점을 1개월 앞으로 예측한 평균오차(MAPE)를 산출하고, 가장 낮은 모델을 타깃별로 선정해 고정한다. 모델들이 유사할 경우 단순한 모델을 우선해 운영 안정성을 확보한다.

2. 예측

사용자가 예측 지평선(개월)을 선택하면, 선정·고정된 모델을 최신 시계열에 적합해 향후 신규·해지 계정수와 신뢰구간을 산출한다. 1~3개월은 수치 예측으로, 그 이상은 방향성 지표로 표시한다.

3. 만기 및 파생 지표 산출

만기는 계약 만기월 기준으로 확정 계산한다. 활성계정·해지율·매출은 신규·해지 예측과 항등식을 결합하며, 활성 base 및 단가표가 주어질 때 산출한다(미입력 시 건수 예측까지 제공).

4. 대시보드 / 보고서 연동

예측값·신뢰구간·선정 모델·정확도를 대시보드에 표시하고, 결과를 상관분석·웹크롤링 결과와 함께 LLM 보고서 입력 데이터로 제공한다.

기술 / 모델 스택

1. 개발 언어

- Python

2. 데이터 처리

- pandas, duckdb : Parquet I/O 및 월별 집계 (pyarrow 버전 이슈로 duckdb 사용)

3. 예측 모델

- statsmodels : ARIMA · SARIMA (SARIMAX), ETS (ExponentialSmoothing), Seasonal-Naive

4. 보조 모델

- scikit-learn : HistGradientBoostingRegressor (채널별 세분화 한정)

5. 검증

- Rolling-origin 백테스트 (MAPE/MAE), 모델 선정 및 정확도 회귀 테스트

6. 저장 / 조회

- Parquet, DuckDB (팀 공통 스택)

7. 시각화 / 인터페이스

- Streamlit, Plotly (기존 대시보드 연동)

검토 필요 사항

1. 매출 환산 입력

SummaryDB에 금액·단가 컬럼이 없음. 모델별 월 구독료 단가표 확보 시 매출 예측으로 확장.

2. 활성계정 base

활성·해지율 레벨 산출을 위해 초기 활성 계정수 스냅샷(약 31,000 이상) 외부 확보 필요.

3. 만기·해지 이중계산

해지에 만기성 해지 포함 여부 확인 후 항등식 정합성 점검.

4. 예측 지평선 한계

1~3개월은 신뢰, 그 이상은 방향성. 의사결정 시 신뢰구간 함께 제시.

5. 세분화 한계

채널·세그먼트 단위는 이력이 짧고 희소해 상위 항목만 예측, 나머지는 상위 그룹 비중으로 배분.

6. 재선정 주기

데이터 누적·구조변화 시 백테스트 재실행 및 모델 재선정 주기 운영 방식 검토.